



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

داده کاوی محاسباتی

گزارش ۲ (استخراج ویژگی مبتنی بر استقلال خطی و تحلیل
تأثیر آن بر فرآیند بهینه سازی توابع زیان)

نگارش

محمدامین نعمتی

شماره دانشجویی

۴۰۴۱۲۴۹۰۴

استاد درس

آقای دکتر قطعی

نیمسال اول ۱۴۰۵-۱۴۰۴

چکیده

در این پروژه، اثر استقلال خطی میان ویژگی‌ها بر عملکرد مدل‌های داده‌کاوی بررسی شده است. سه مجموعه داده با ماهیت طبقه‌بندی، رگرسیون و خوشه‌بندی مورد تحلیل قرار گرفتند. برای کاهش هم‌خطی و استخراج ساختارهای مؤثر داده، از روش‌های کاهش بُعد و همچنین انتخاب ویژگی استفاده شد. نتایج نشان داد کاهش بُعد سبب بهبود پایداری ضرایب در مدل‌های خطی، بهبود جداسازی خوشه‌ها در الگوریتم‌های مبتنی بر فاصله و کاهش زمان همگرایی در روش‌های بهینه‌سازی می‌شود. همچنین مشخص گردید مدل‌های مبتنی بر درخت در برابر هم‌خطی مقاوم‌اند و ترکیب استخراج و انتخاب ویژگی می‌تواند توازن مناسبی میان سادگی، تفسیرپذیری و کارایی ایجاد کند.

واژه‌های کلیدی:

استخراج ویژگی، انتخاب ویژگی، استقلال خطی، کاهش بُعد، خوشه‌بندی

چکیده.....	أ
فصل اول مقدمه.....	۱
فصل دوم استخراج و انتخاب ویژگی‌ها.....	۵
۱-۲- استخراج ویژگی‌های مستقل با روش‌های کاهش بُعد	۵
۲-۲- انتخاب ویژگی‌های مهم با روش‌های پایه	۶
فصل سوم مدل‌سازی رگرسیونی و تحلیل پایداری ضرایب.....	۷
فصل چهارم بهینه‌سازی بدون مشتق و تحلیل خوشه‌بندی داده‌ها.....	۱۰
فصل پنجم مدل‌سازی طبقه‌بندی و ارزیابی دقت پیش‌بینی.....	۱۳
فصل ششم نتیجه‌گیری.....	۱۷
Abstract.....	۱۹

فصل اول


مقدمه

مقدمه


در این پروژه، هدف اصلی تحلیل اثر استقلال خطی ویژگی‌ها بر بهینه‌سازی مدل‌های داده‌کاوی است. برای این منظور، از سه مجموعه داده‌ی **Breast Cancer**، **California Housing** و **Iris** استفاده شده است که مشخصات آن‌ها در جدول ۱-۱ ارائه گردیده است. توزیع متغیرهای هدف در شکل ۱-۱ نمایش داده شده و جهت بررسی هم‌خطی میان ویژگی‌ها، نقشه حرارتی همبستگی (شکل ۲-۱) و مقادیر VIF در جدول ۲-۱ آورده شده است تا میزان وابستگی خطی در داده‌ها به‌صورت عددی و بصری تحلیل گردد.

جدول ۱-۱ ویژگی‌های مجموعه داده‌ها

Dataset	Rows	Features	Task Type	Target / Classes	Class Distribution
Breast Cancer	569	30	Classification	Benign (0), Malignant (1)	Benign: 357 / Malignant: 212
California Housing	20,640	8	Regression	Median House Value	—
Iris	150	4	Clustering	Setosa, Versicolor, Virginica	50 / 50 / 50



شکل ۱-۱ توزیع متغیرهای هدف در سه مجموعه داده



شکل ۱-۲ نقشه حرارتی همبستگی میان ویژگی‌های مجموعه داده‌ها

جدول ۱-۲ همبستگی‌های بالا و شاخص تورم واریانس

Dataset	Pairs with $ \text{corr} > 0.8$	VIF (Variance Inflation Factor)	Features with VIF > 10
Breast Cancer	mean radius — mean perimeter: 0.997855 worst radius — worst perimeter: 0.993708 mean radius — mean area: 0.987357 mean perimeter — mean area: 0.986507 worst radius — worst area: 0.984015 worst perimeter — worst area: 0.977578 radius error — perimeter error: 0.972794 mean perimeter — worst perimeter: 0.970387 mean radius — worst radius: 0.969539 mean perimeter — worst radius: 0.969476 ...	mean radius: 63,306.172036 mean perimeter: 58,123.586079 worst radius: 9,674.742602 worst perimeter: 4,487.781270 mean area: 1,287.262339 worst area: 1,138.759252 mean fractal dimension: 629.679874 worst fractal dimension: 423.396723 mean smoothness: 393.398166 worst smoothness: 375.597155 ...	mean radius; mean perimeter; worst radius; worst perimeter; mean area; worst area; mean fractal dimension; worst fractal dimension; mean smoothness; worst smoothness; worst texture; mean texture; radius error; worst symmetry; perimeter error; mean compactness; mean symmetry; mean concavity; mean concave points; worst concave points; worst compactness; worst concavity; area error; concave points error; compactness error; symmetry error; concavity error; fractal dimension error; smoothness error; texture error
California Housing	Latitude — Longitude: 0.924664 AveRooms — AveBedrms: 0.847621	Longitude: 633.711654 Latitude: 559.874071 AveRooms: 45.993601 AveBedrms: 43.590314 MedInc: 11.511140 HouseAge: 7.195917 Population: 2.935745 AveOccup: 1.095243	Longitude; Latitude; AveRooms; AveBedrms; MedInc
Iris	petal length (cm) — petal width (cm): 0.962865 sepal length (cm) — petal length (cm): 0.871754 sepal length (cm) — petal width (cm): 0.817941	sepal length (cm): 262.969348 petal length (cm): 172.960962 sepal width (cm): 96.353292 petal width (cm): 55.502060	sepal length (cm); petal length (cm); sepal width (cm); petal width (cm)

فصل دوم

استخراج و انتخاب ویژگی‌ها


استخراج و انتخاب ویژگی‌ها

در این فصل با روش‌های PCA، SVD، ICA ویژگی‌های مستقل استخراج و در جدول ۱-۲ و شکل ۱-۲ نشان داده شده است؛ سپس با SelectKBest و RFE ویژگی‌های مهم هر مجموعه داده شناسایی گردیده است.

۱-۲- استخراج ویژگی‌های مستقل با روش‌های کاهش بُعد

جدول ۱-۲ خلاصه استخراج ویژگی‌ها

Dataset	PCA Components	SVD Components	ICA Components	PCA EVR (1st Comp)	SVD EVR (1st Comp)
Cancer	10	10	10	0.443	0.443
Housing	6	6	6	0.253	0.253
Iris	2	2	3	0.730	0.730




شکل ۱-۲ مقایسه استخراج ویژگی با PCA، SVD و ICA در سه مجموعه داده

۲-۲- انتخاب ویژگی‌های مهم با روش‌های پایه

جدول ۲-۲ خلاصه ویژگی‌های انتخاب‌شده با RFE و SelectKBest

Dataset	SelectKBest Features	RFE Features	KBest Count	RFE Count
Breast Cancer	mean perimeter, mean concave points, worst radius, worst perimeter, worst concave points	radius error, worst radius, worst texture, worst area, worst concave points	5	5
California Housing	MedInc, HouseAge, AveRooms, AveBedrms, Latitude	MedInc, AveRooms, AveBedrms, Latitude, Longitude	5	5
Iris	sepal length (cm), sepal width (cm), petal length (cm), petal width (cm)	sepal length (cm), sepal width (cm), petal length (cm), petal width (cm)	4	4



شکل ۲-۲ مقایسه بصری ویژگی‌های انتخاب‌شده با RFE و SelectKBest در سه مجموعه داده


روش‌های استخراج ویژگی مانند PCA با حذف هم‌خطی، فضای داده‌ای پایدارتر و فشرده‌تری ایجاد می‌کنند، در حالی که روش‌های انتخاب ویژگی نظیر RFE بر حفظ تفسیرپذیری داده‌ها تمرکز دارند. مقایسه در جدول ۲-۲ و شکل ۲-۲ نشان می‌دهد هر دو رویکرد مکمل یکدیگرند و ترکیب آن‌ها می‌تواند در بهبود عملکرد مؤثر باشد.

فصل سوم

مدل سازی رگرسیونی و تحلیل پایداری ضرایب

مدل سازی رگرسیونی و تحلیل پایداری ضرایب

در این بخش، پایداری ضرایب مدل های رگرسیونی و رفتار آنها در داده های اصلی و کاهش بعدیافته با PCA بررسی شده است. همان طور که در شکل ۱-۳ و جدول ۱-۳ مشاهده می شود، کاهش هم خطی



باعث بهبود شرط عددی و همگرایی سریع تر الگوریتم SGD شده است.

شکل ۱-۳ همگرایی SGD برای η_0 های مختلف

جدول ۱-۳ پایداری ضرایب و عملکرد LinearRegression روی داده های اصلی و PCA

Metric	Original Data	PCA Data ($n_{pca}=6$)
Dimensions	(20640, 8)	(20640, 6)
Coef norm	1.5606	0.8204
Max	coef	
Condition number	6.668	1.753
MSE	0.52432	0.65868
R ²	0.6062	0.5053

جدول ۲-۳ خلاصه تنظیم η_0 در SGD و تعداد اپوک ها برای رسیدن به آستانه خطا


η_0	final MSE (Original)	final MSE (PCA)	Epochs to 1% error (Original)	Epochs to 1% error (PCA)
0.001	0.52440	0.65871	21	2
0.005	0.52597	0.65918	4	2
0.010	0.52723	0.66040	10	15
0.050	9.10e+21	9.10e+21	1	1
0.100	2.65e+22	1.76e+22	1	1

فصل چهارم

بهینه‌سازی بدون مشتق و تحلیل خوشه‌بندی داده‌ها

بهینه‌سازی بدون مشتق و تحلیل خوشه‌بندی داده‌ها

در شکل ۱-۴ مشاهده می‌شود که کاهش بعد با PCA سبب جداسازی واضح‌تر خوشه‌ها و کاهش زمان همگرایی الگوریتم KMeans شده است. همچنین همان‌طور که در جدول ۱-۴ آمده، نسخه PCA با ۲ مؤلفه کمترین مقدار اینرسی و بالاترین مقدار سیلوئت را داشته و در نتیجه ساختار خوشه‌ای منسجم‌تر و تفکیک‌پذیرتری ارائه داده است.



شکل ۱-۴ مقایسه عملکرد KMeans روی داده‌های اصلی و داده‌های کاهش‌یافته با PCA

جدول ۱-۴ خلاصه نتایج خوشه‌بندی KMeans روی داده‌های Iris

Variant	Samples	Components	Value1	Value2	Value3	Value4
original_scaled	150	4	191.02	0.4799	0.0030	4
pca_2	150	2	166.04	0.5228	0.0019	5
pca_3	150	3	187.95	0.4857	0.0017	4

فصل پنجم


مدل سازی طبقه بندی و ارزیابی دقت پیش بینی

مدل سازی طبقه بندی و ارزیابی دقت پیش بینی

همان طور که در جدول ۱-۵ ملاحظه می شود، کاهش بعد با PCA دقت مدل KNN را تقریباً ثابت نگاه می دارد اما زمان پیش بینی را کمی افزایش می دهد، در حالی که برای RandomForest کاهش بعد با PCA و SelectKBest موجب افت جزئی دقت شده است.

جدول ۱-۵. مقایسه عملکرد مدل های KNN و RandomForest در فضاهای ویژگی مختلف

model	variant	n_features	fit_time_s	predict_time_s	accuracy
KNN	orig	30	0.0011	0.003886	0.9561
KNN	pca	10	0.0016	0.006115	0.9561
RandomForest	orig	30	1.1168	0.059186	0.9561
RandomForest	pca	10	0.7981	0.056431	0.9386
RandomForest	kbest	5	0.9450	0.066445	0.9298




شکل ۱-۵ دقت و زمان پیش بینی مدل های KNN و RandomForest در نسخه های مختلف فضای ویژگی

در شکل ۱-۵ نیز مشخص است که ساده سازی فضای ویژگی باعث کاهش زمان آموزش و پیش بینی به ویژه در RandomForest شده و این موضوع نیز نشان می دهد که مدل های مبتنی بر درخت نسبت به هم خطی مقاوم هستند، اما حساسیت بیشتری به کاهش اطلاعات کلیدی ویژگی ها دارند.

فصل ششم

جمع‌بندی و نتیجه‌گیری

جمع‌بندی و نتیجه‌گیری




شکل ۱-۶ پایداری ضرایب و همگرایی SGD در داده‌های اصلی و PCA

جدول ۱-۶ مقایسه پایداری ضرایب و همگرایی SGD

حالت	Norm ضرایب	عدد شرط	MSE	اپوک همگرایی SGD
داده اصلی	1.5606	6.668	0.52432	9
PCA	0.8204	1.753	0.65868	13

استقلال خطی ایجادشده توسط PCA باعث کاهش هم‌خطی و در نتیجه پایداری بیشتر ضرایب در مدل LinearRegression شد. همان‌طور که در جدول ۱-۶ دیده می‌شود کاهش عدد شرط از ۶.۶۶۸ به ۱.۷۵۳ نشان‌دهنده کاهش حساسیت مدل به تغییرات داده است. الگوریتم SGDRegressor روی داده PCA شده هموارتر و پایدارتر همگرا شد اما با توجه به کاهش اطلاعات، به اپوک‌های بیشتری نیاز داشت. این الگو در شکل ۱-۶ نمایان است؛ منحنی PCA لرزش کمتر و شیب همگرایی منظم‌تری دارد.




شکل ۲-۶ مقایسه خوشه‌بندی KMeans در فضاهای ویژگی مختلف (Original, PCA-2D, PCA-3D)

جدول ۶-۲ نتایج خوشه‌بندی KMeans

نسخه	Inertia (کمتر بهتر)	Silhouette (بیشتر بهتر)	(s) زمان آموزش
Original	139.820496	0.459948	0.034474
PCA-2D	115.020757	0.509168	0.023967
PCA-3D	136.815513	0.466131	0.044941

کاهش بعد با PCA به دو مؤلفه کیفیت خوشه‌بندی (افزایش Silhouette) را بهبود داد و سرعت KMeans را کاهش داد، زیرا KMeans و KNN بر فاصله اقلیدسی تکیه دارند و در فضای با ابعاد زیاد فاصله‌ها قابل اعتماد نیستند؛ PCA ساختار هندسی داده را فشرده و معنادار می‌کند.

Q4 & Q5: Classification Comparison



شکل ۶-۳ مقایسه دقت و زمان اجرای KNN و RandomForest در نسخه‌های Original / PCA /

SelectKBest

جدول ۳-۶ خلاصه نتایج Classification

مدل	نسخه داده	دقت (Accuracy)	توضیح
KNN	PCA	بدون تغییر، سرعت پیش‌بینی کمتر	KNN به فاصله حساس است، PCA ساختار را ساده می‌کند.
RF	Original	KBest و PCA نسخه‌های	RandomForest به هم‌خطی حساس نیست.

مدل‌های مبتنی بر درخت مثل RandomForest به دلیل مقاومت در برابر هم‌خطی روی داده‌های اولیه عملکرد خوبی دارند، روش‌های کاهش ابعاد مانند PCA برای مدل‌های مبتنی بر فاصله مؤثرترند و روش‌هایی مثل SelectKBest یا RFE برای مدل‌های قابل تفسیر مزیت سادگی و قابلیت تفسیر دارند؛ بنابراین انتخاب روش به نوع مدل بستگی دارد.

جدول ۴-۶ جمع‌بندی نهایی

نتیجه	معیار
بهبود PCA	پایداری ضرایب خطی
PCA مستقل	سرعت همگرایی SGD
PCA-2D	کیفیت خوشه‌بندی
PCA مؤثرتر از انتخاب ویژگی	عملکرد KNN
مقاوم به هم‌خطی	عملکرد RandomForest
استخراج ویژگی (PCA) برای مدل‌های فاصله‌ای؛ انتخاب ویژگی برای مدل‌های تفسیری	برتری کلی

کاهش بعد با PCA نه تنها موجب افزایش استقلال ویژگی‌ها و پایداری تخمین ضرایب شد، بلکه در مسائل خوشه‌بندی و مدل‌های مبتنی بر فاصله، سرعت و کیفیت طبقه‌بندی را نیز بهبود داد. از سوی دیگر، مدل‌های درختی مانند RandomForest نیاز ضروری به حذف هم‌خطی ندارند و پایدار باقی می‌مانند.

بنابراین ادغام استخراج ویژگی مانند PCA با انتخاب ویژگی مانند SelectKBest یا RFE می‌تواند به ساخت مدل‌های پایدارتر، سریع‌تر و قابل تفسیرتر کمک کند. این ترکیب، برای یک متخصص داده‌کاوی ابزاری کلیدی و کاربردی است.

Abstract

This study examines the effect of linear independence among features on the performance of data mining models. Three datasets with classification, regression, and clustering tasks were analyzed. To reduce multicollinearity and extract meaningful structure from the data, dimensionality reduction methods as well as feature selection techniques were applied. The results show that reducing dimensionality improves coefficient stability in linear models, enhances cluster separation in distance-based algorithms, and shortens convergence time in optimization processes. It was also observed that tree-based models are inherently resistant to multicollinearity, and that combining feature extraction with feature selection provides a balanced trade-off between simplicity, interpretability, and performance.

Keywords: Feature extraction, Feature selection, Linear independence, Dimensionality reduction, Clustering

GITHUB LINK

https://github.com/nematiamin57-pixel/data_mining1404



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department of Computer Science

Computational Data Mining

**Report 2: Feature Extraction Based on Linear
Independence and Analysis of Its Impact on the
Optimization of Loss Functions**

**By
Mohammadamin Nemati**

**Student ID
404124904**

**Lecturer
Dr. Ghatte**

First Semester of the 2025–2026 Academic Year