



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

داده کاوی محاسباتی

گزارش ۴: هندسه یادگیری (انحنا، تعامد و هزینه محاسباتی در
شبکه‌های عصبی)

نگارش

محمدامین نعمتی

شماره دانشجویی

۴۰۴۱۲۴۹۰۴

استاد درس

آقای دکتر قطعی

نیمسال اول ۱۴۰۵-۱۴۰۴

چکیده

این گزارش به بررسی نقش هندسه سطح خطا—از جمله انحنا، عدد وضعیت و ساختار ویژگی‌ها—در رفتار الگوریتم‌های بهینه‌سازی در سه مقیاس متفاوت می‌پردازد: توابع درجه‌دو، شبکه‌های کم‌عمق و شبکه‌های عمیق. نتایج نشان می‌دهد که در مسائل با هسین نامتوازن، روش‌های مرتبه‌دوم و شبه‌مرتبه‌دوم (مانند نیوتون، L-BFGS و CG) نسبت به گرادیان‌دیسنت عملکرد به‌مراتب بهتری دارند. در شبکه‌های کم‌عمق، الگوریتم‌های شبه‌نیوتنی خطای نهایی بسیار پایین‌تری به‌دست می‌دهند، هرچند هزینه زمانی هر گام بیشتر است. در شبکه‌های عمیق، روش‌های تطبیقی مانند Adam به‌دلیل تنظیم پویا در نرخ یادگیری، هم از نظر سرعت و هم دقت برتری عملی دارند و استفاده مستقیم از روش‌های مرتبه‌دوم به‌دلیل محدودیت حافظه‌ای (دیوار هسین) غیرقابل‌اجراست. بررسی تأثیر QR نشان می‌دهد که دکورلاسیون ویژگی‌ها می‌تواند مفید باشد، اما پیاده‌سازی نادرست یا ناسازگاری بین فضای آموزش و تست می‌تواند نتیجه را معکوس سازد. این تحلیل‌ها اهمیت انتخاب روش بهینه‌سازی متناسب با ساختار مسئله و ابعاد مدل را برجسته می‌کند.

واژه‌های کلیدی:

بهینه‌سازی، گرادیان مزدوج، شبکه‌های عمیق، هسین، مقیاس‌پذیری

صفحه

فهرست مطالب

أ.....	چکیده.....
۱.....	فصل اول.....
۵.....	فصل دوم.....
۷.....	فصل سوم.....
۱۰.....	فصل چهارم.....
۱۳.....	فصل پنجم.....
۱۷.....	فصل ششم نتیجه گیری.....
۱۹.....	Abstract.....

فصل اول

مقدمه

این گزارش بر اساس پروژه تمرین چهارم درس «داده‌کاوی محاسباتی» تنظیم شده و هدف آن بررسی تأثیر هندسه سطح خطا (انحنا)، روش‌های بهینه‌سازی مرتبه اول و دوم و نقش تعامد ویژگی‌ها در رفتار بهینه‌سازی است. پروژه در چهار بخش تجربی و تحلیلی طراحی شده است: (۱) تحلیل ریاضی بر روی تابع درجه‌دو بدحالت، (۲) مقایسه بهینه‌سازها در یک MLP کم‌عمق، (۳) تحلیل مقیاس‌پذیری و محدودیت‌های مرتبه دوم در شبکه‌های عمیق و (۴) بررسی اثر تجزیه QR و دکورلاسیون روی رفتار SGD در رگرسیون خطی. در گزارش حاضر، هر بخش شامل شرح تنظیم آزمایش، ارائه نتایج عددی و تصویری (به‌صورت فشرده)، تفسیر نتایج با ارجاع به جدول/شکل و پیشنهادات عملی است.

فصل دوم


تحلیل‌های ریاضی

این آزمایش روی یک تابع مربعی دوبعدی با هسین نامتوازن و نقطه شروع $[۲.۰, ۳.۰]$ انجام شده است. همان‌طور که در جدول ملاحظه می‌شود، گرادیان‌دیسنت پس از تعداد زیادی گام در نقطه حدودی $[۰.۲۶۲۳۳۷۲۷۱, ۱.۶۵ \times 10^{-24}]$ مقدار بسیار نزدیک به صفر با هزینه نهایی $۱.۰ \times ۳.۴۴ \times 10^{-2}$ متوقف می‌شود، در حالی که روش نیوتون مستقیماً به نقطه $[۰, ۰]$ با هزینه صفر همگرا می‌شود. روش گرادیان مزدوج نیز به مقادیر تقریباً صفر $[-۱.۰ \times ۴.۴۴ \times 10^{-16}, -۱.۰ \times ۸.۲۷ \times 10^{-15}]$ با هزینه $۱.۰ \times ۱.۷۱ \times 10^{-27}$ می‌رسد. این اختلاف عددی نشان می‌دهد که روش‌های مرتبه دوم نسبت به گرادیان‌دیسنت در این مسئله بد شرط عملکرد بسیار بهتری دارند.

مسیر بهینه‌سازها در تابع درجه‌دو

Method	Start position	Final position	Cost
Gradient Descent	[3.0, 2.0]	[0.262337271, 1.65×10^{-24}]	3.44×10^{-2}
Newton's Method	[3.0, 2.0]	[0.0, 0.0]	0.0
Conjugate Gradient	[3.0, 2.0]	$[-4.44 \times 10^{-16}, -8.27 \times 10^{-15}]$	1.71×10^{-27}


در شکل کانتورهای تابع درجه‌دو و مسیر حرکت بهینه‌سازها نیز دیده می‌شود که مسیر گرادیان‌دیسنت حالت زیگ‌زاگی دارد؛ مؤلفه y خیلی سریع به صفر می‌رسد اما کاهش مؤلفه x کند و همراه با نوسان است، زیرا دره تابع به شدت کشیده و باریک است. در مقابل، مسیرهای روش نیوتون و گرادیان مزدوج تقریباً مستقیم و بدون نوسان به سمت مرکز مینیمم حرکت می‌کنند. ترکیب این مشاهدات هندسی با نتایج جدول، به روشنی نشان می‌دهد که هسین نامتوازن و عدد وضعیت بالا موجب کندی و نوسان در گرادیان‌دیسنت شده، در حالی که دو روش دیگر با اصلاح مقیاس مسیر، سریع و دقیق همگرا می‌شوند.



فصل سوم

شبکه عصبی کلاسیک

در این آزمایش یک شبکه MLP کم عمق با کمتر از ۵۰۰ پارامتر روی دیتاست Breast Cancer آموزش داده شد. همان طور که در جدول «زمان و خطای آموزش در MLP کم عمق گزارش شده، روش SGD به خطای نهایی ۰.۰۷۷۴۲۱۱۹۸۱ با زمان ۰.۰۷۱۸ ثانیه رسیده است. روش L-BFGS خطای بسیار پایین تری برابر با ۰.۰۳۱۴۹۱۳۶۶ به دست داده اما زمان اجرای آن ۱.۱۸۱۹ ثانیه بوده است. روش Conjugate Gradient نیز با خطای ۰.۰۰۹۲۳۴۰۰۶۲ و زمان ۰.۱۳۷۵ ثانیه عملکردی میان این دو ارائه کرده است. این اعداد نشان می دهند که استفاده از اطلاعات تقریبی خمیدگی در روش های L-BFGS و CG باعث کاهش محسوس خطای نهایی می شود، هرچند هزینه زمانی هر گام در آن ها بیشتر از SGD است.



رابطه زمان و خطای آموزش در MLP کم عمق

در شکل رابطه زمان و خطای آموزش در MLP کم عمق مشاهده می شود که L-BFGS با وجود صرف زمان بیشتر، کمترین خطا را به دست آورده و ساختار کم عمق و کم پارامتر مدل به این روش اجازه داده تا به سرعت به ناحیه بهینه دقیق برسد CG نیز نسبت به SGD خطای کمتر و نسبت به L-BFGS زمان کوتاه تری دارد و بنابراین موقعیتی میانی را اشغال می کند. در مقابل، SGD که هزینه هر گام آن بسیار کم است، سریع تر اجرا می شود اما به خطای نهایی بالاتری می رسد. این رفتارها در کنار هم تأیید می کنند که در مدل های کوچک، اختلاف روش ها در استفاده از اطلاعات هندسی تابع هزینه نقش تعیین کننده ای در کیفیت همگرایی دارد.

زمان و خطای آموزش در MLP کم عمق

Method	Final Loss	Time (s)
SGD	0.0774211981	0.0718
L-BFGS	0.0031491366	1.1819
Conjugate Gradient	0.0092340062	0.1375

فصل چهارم


شبکه‌ی عمیق و تله‌ی مقیاس‌پذیری

یک شبکه عمیق با سه لایه مخفی، هر کدام ۱۰۰ نورون، روی یک دیتاست نماینده مثلاً MNIST یا Fashion-MNIST آموزش داده شد. نتایج ثبت‌شده در جدول زیر آمده است:

Method	Final Loss	Time (s)
SGD	2.271965	2.47
Adam	0.011693	1.26

در کنار این، برآوردی از بعد هسین و حافظه مورد نیاز برای نگهداری ماتریس هسین $N \times N$ با اعداد float32 انجام شد و نتیجه این بود که ذخیره کامل هسین برای شبکه‌های نسبتاً بزرگ عملی نیست.

شکل «مقایسه SGD و Adam در MLP عمیق» منحنی‌های کاهش خطا نسبت به زمان را نشان می‌دهد. Adam هم سریع‌تر هم با خطای نهایی بسیار کمتر همگرا شده است. این رفتار با خاصیت تطبیق Adam سازگار است، زیرا Adam نرخ یادگیری را به ازای هر پارامتر براساس تاریخچه گرادیانت تنظیم می‌کند و اثر نویز مینی‌بچ‌ها را تعدیل می‌کند. محاسبات مربوط به ابعاد هسین و برآورد حافظه نیز نشان می‌دهد که اجرای مستقیم روش‌های مرتبه دوم (مثل نیوتون خالص) روی چنین شبکه‌ای از نظر حافظه و محاسباتی غیرقابل اجراست.



فصل پنجم


رویکرد داده‌کاوی

در این آزمایش داده‌های رگرسیونی مصنوعی با ویژگی‌های بسیار همبسته تولید شد. سپس تجزیه QR روی ماتریس ویژگی‌ها انجام گرفت. مدل رگرسیون خطی با SGD روی داده خام X و روی داده متعامد Q آموزش داده شد. نتایج MSE نهایی در جدول زیر آمده است:

کوواریانس نمونه و MSE نهایی


Model / preprocessing	Final MSE
raw X	0.003463
orthogonalized Q	0.995460

این نتیجه برخلاف انتظار تئوریک اولیه است که پیش‌بینی می‌کرد تبدیل QR با دکورله کردن ستون‌ها عدد وضعیت را بهبود دهد و عملکرد SGD را بهتر کند.



کوواریانس نمونه ویژگی‌ها در مجموعه آموزش

شکل «کوواریانس نمونه ویژگی‌ها در مجموعه آموزش» همبستگی‌های قوی بین ویژگی‌ها را نشان می‌دهد. شکل‌های مقایسه‌ای MSE باید تفاوت عملکرد روی X و Q را به‌وضوح نمایش دهند.



اثر تجزیه QR بر عملکرد SGD در رگرسیون خطی

فصل ششم

جمع‌بندی و نتیجه‌گیری

در این گزارش نشان داده شد که هندسه سطح خطا — به‌ویژه انحنا و عدد وضعیت — نقش محوری در رفتار الگوریتم‌های بهینه‌سازی ایفا می‌کند. نکات کلیدی عبارت‌اند از:

- برای مسائل با عدد وضعیت بالا، روش‌های مرتبه دوم یا شبه‌مرتبه دوم نیوتون، CG، L-BFGS می‌توانند همگرایی بسیار سریع‌تری نسبت به GD ارائه دهند، اما هزینه حافظه و محاسبات برای شبکه‌های بزرگ محدودیت‌ساز است.
- در شبکه‌های عمیق، الگوریتم‌های تطبیقی مثل Adam مزیت عملی قابل‌توجهی دارند و غالباً wall-clock time همگرایی را کاهش می‌دهند؛ با این حال بررسی منحنی‌های اعتبارسنجی الزامی است تا از تعمیم‌پذیری مطمئن شویم.
- دکوراسیون ویژگی‌ها برای مثال با QR می‌تواند بهبود عدد وضعیت و پایداری روش‌های مبتنی بر گرادینان را فراهم کند، اما پیاده‌سازی باید با دقت انجام و سازگاری بین فضای آموزش و تست حفظ شود.

Abstract

This report examines the role of the error surface geometry—including curvature, condition number, and feature structure—on the behavior of optimization algorithms across three different scales: quadratic functions, shallow networks, and deep networks. The results show that in problems with ill-conditioned Hessians, second-order and quasi-second-order methods (such as Newton, L-BFGS, and Conjugate Gradient) perform significantly better than gradient descent. In shallow networks, quasi-Newton algorithms achieve much lower final error, although the computational cost per step is higher. In deep networks, adaptive methods like Adam offer practical advantages in both speed and accuracy due to dynamic adjustment of learning rates, while direct use of second-order methods is impractical because of memory constraints (Hessian wall). Examination of the QR effect indicates that feature decorrelation can be beneficial, but improper implementation or inconsistency between training and test spaces can reverse the expected outcomes. These analyses highlight the importance of selecting an optimization method appropriate to the problem structure and model scale.

Key Words: Optimization, Conjugate Gradient, DNN, QR, Hessian, Scalability

GITHUB LINK

https://github.com/nematiamin57-pixel/data_mining1404



**Amirkabir University of Technology
(Tehran Polytechnic)**

Department of Computer Science

Computational Data Mining

**Report 4: Geometry of Learning (Curvature,
Orthogonality, and Computational Cost in
Neural Networks)**

**By
Mohammadamin Nemati**

**Student ID
404124904**

**Lecturer
Dr. Ghatte**

First Semester of the 2025–2026 Academic Year